



UNIVERSIDADE ESTADUAL DA PARAÍBA – UEPB
CENTRO DE CIÊNCIAS E TECNOLOGIA
DEPARTAMENTO DE ESTATÍSTICA
CURSO DE BACHARELADO EM ESTATÍSTICA

Componente Curricular: **Análise de Sobrevivência**
Professor: **Cleanderson R. Fidelis**

Atividade Avaliativa: Seminário e Relatório Técnico

Esta atividade é individual e tem por finalidade integrar preparação de dados, análise não paramétrica, modelagem de sobrevivência, diagnóstico estatístico e comunicação científica. Cada estudante receberá uma base geográfica e deverá escolher nela um tipo específico de câncer. O resultado será apresentado em um relatório técnico reprodutível e em um seminário.

Ao final do trabalho, espera-se que o estudante seja capaz de definir uma coorte, construir corretamente o tempo e o indicador de evento, reconhecer censura, estimar funções de sobrevivência e selecionar uma estratégia de regressão compatível com a pergunta e com os dados.

1 Bases de dados

Os quatro arquivos originais fornecidos são:

- `base_nao_identificada_5549_goiias.csv`;
- `base_nao_identificada_5550_belo_horizonte.csv`;
- `base_nao_identificada_5551_porto_alegre.csv`;
- `base_nao_identificada_5552_pocos_de_caldas.csv`.

Os arquivos são separados por ponto e vírgula e os originais usam codificação Latin-1. As bases de Belo Horizonte e Poços de Caldas deverão ser empilhadas e tratadas como uma única base de Minas Gerais. A variável `Nome` do `RCBP` deverá ser preservada para identificar a origem de cada registro.

Portanto, os quatro arquivos originais correspondem a três unidades de análise: Goiânia, Porto Alegre e Minas Gerais (Belo Horizonte + Poços de Caldas).

2 Resultado do sorteio

As bases de dados foram separadas por critérios técnicos.

Nº	Estudante	Matrícula	Base sorteada
1	Alessandra Paulo Dias de Oliveira	221090274	Goiânia (GO)
2	Ana Maria Fernandes Costa	2024109510042	Porto Alegre (RS)
3	Anatalia Antonia da Silva	221090525	Porto Alegre (RS)
4	Jefferson Balbino Rodrigues	212090755	Porto Alegre (RS)
5	Pedro Henrique Rodrigues Pereira	191090336	Goiânia (GO)
6	Ray Vinicius Barbosa de Andrade	221090231	Minas Gerais (Belo Horizonte + Poços de Caldas)
7	Richard Matheus Avelino da Silva	212090216	Porto Alegre (RS))
8	Thaisa Erika da Costa Azevedo	202090477	Goiânia (GO)

3 Escolha do tipo de câncer e estudo de viabilidade

O sorteio define somente a base geográfica. Cada estudante deverá examinar os tipos de câncer nela disponíveis e selecionar um tipo específico. Estudantes que receberam a mesma base deverão escolher tipos diferentes.

A escolha deverá ser comunicada ao professor antes da análise principal e deverá conter: descrição do câncer, código da doença ou da topografia, regra completa de filtragem, número inicial de registros, número de eventos e número de censuras potencialmente utilizáveis. A prioridade será de quem primeiro registrar uma escolha viável. Quando pertinente, a definição poderá combinar topografia e morfologia; a descrição textual isolada não constitui regra suficiente de seleção.

Essa etapa funciona como uma verificação de viabilidade. Se houver poucos eventos, ausência de censuras confiáveis, falta de variabilidade nas covariáveis ou outro impedimento relevante, o estudante deverá discutir com o professor a troca do tipo de câncer ou uma adequação do escopo antes de prosseguir.

4 Etapas da análise

4.1 Pergunta, população e definição da coorte

- Formule uma pergunta de pesquisa objetiva e identifique a população-alvo, a população efetivamente observada e o desfecho de interesse.
- Justifique a escolha do tipo de câncer e apresente os códigos usados para identificá-lo.
- Defina os critérios de inclusão e exclusão e apresente um fluxograma ou uma tabela com o número de registros removidos em cada etapa.
- Verifique duplicidades, categorias “sem informação”, dados ausentes, datas inválidas e inconsistências cronológicas. Apresente um dicionário apenas das variáveis efetivamente utilizadas.

- e) Para Minas Gerais, descreva a união das bases e apresente a composição da coorte segundo o RCBP de origem. Verifique também se os períodos de diagnóstico e de acompanhamento dos dois registros são comparáveis; se necessário, defina e justifique uma janela de calendário comum.
- f) Informe o intervalo de anos de diagnóstico incluído e discuta se mudanças temporais no diagnóstico, no tratamento ou na qualidade do registro podem afetar a análise.

4.2 Tempo, evento e censura

A origem do tempo será, em princípio, a **Data de Diagnostico**. A data final deverá ser construída a partir das informações documentadas de óbito ou último contato. Para o indivíduo i :

$$T_i = \text{data final}_i - \text{data de diagnóstico}_i,$$

$$\delta_i = \begin{cases} 1, & \text{evento observado,} \\ 0, & \text{censura à direita.} \end{cases}$$

O relatório deverá declarar a unidade do tempo, a definição exata do evento e as regras usadas para reconciliar **Status Vital**, **Tipo do Óbito**, **Data do Óbito** e **Data de Último Contato**. Também deverá informar como foram tratados tempos nulos ou negativos, campos discordantes e registros sem seguimento. Não se deve criar datas, eventos ou censuras não documentados.

Se o evento for óbito por câncer, explique o tratamento dado aos óbitos por outras causas e reconheça as implicações dessa escolha. Se o evento for óbito por qualquer causa, declare-o explicitamente. Apresente o tamanho da coorte final, o número e a proporção de eventos e censuras e um resumo do tempo de acompanhamento.

A base de Goiânia apresenta limitações importantes em **Status Vital** e **Data de Último Contato**. Os estudantes dessa base deverão quantificar o problema antes de qualquer ajuste. Registros sem data de óbito não podem ser automaticamente classificados como censurados, e não se deve adotar uma data de encerramento arbitrária. Se não for possível construir uma coorte válida, o estudante deverá consultar o professor para redefinir a análise.

4.3 Análise descritiva e não paramétrica

Para uma coorte com tempo e evento válidos:

- a) descreva a amostra por variáveis demográficas e clínicas pertinentes, sempre informando os denominadores e os dados ausentes;
- b) estime a função de sobrevivência por Kaplan–Meier, com intervalo de 95% de confiança, marcas de censura e tabela do número em risco;
- c) apresente a mediana de sobrevivência e outras probabilidades de sobrevivência em tempos clinicamente relevantes, quando estimáveis;
- d) estratifique a curva por ao menos uma variável justificada pela pergunta de pesquisa e compare as curvas pelo teste log-rank;

- e) estime e interprete a função de risco acumulado de Nelson–Aalen.

O valor de p do teste log-rank não deverá ser interpretado isoladamente. Considere o formato das curvas, a magnitude das diferenças, os intervalos de confiança, o número em risco e a relevância prática. Para Minas Gerais, inclua uma comparação exploratória entre os dois RCBP, sem atribuir interpretação causal às diferenças.

4.4 Modelagem: escolha entre Cox e AFT

O estudante deverá escolher uma das duas rotas de modelagem abaixo. Não é obrigatório ajustar as duas. A escolha deverá ser justificada pela pergunta de pesquisa, pelo comportamento dos dados e pelos pressupostos do modelo. Caso as duas sejam ajustadas, uma delas deverá ser definida como análise principal.

4.4.1 Rota A: modelo de riscos proporcionais de Cox

- a) Defina previamente as covariáveis e suas categorias de referência.
- b) Apresente razões de riscos, intervalos de 95% de confiança e valores de p , acompanhados de interpretação no contexto do estudo.
- c) Verifique a suposição de riscos proporcionais globalmente e por covariável, utilizando diagnóstico apropriado e inspeção gráfica.
- d) Avalie, quando pertinente, a forma funcional de covariáveis contínuas, observações influentes e possíveis interações justificadas.
- e) Se a proporcionalidade não for plausível, considere estratificação, efeito dependente do tempo ou outra adequação e explique suas consequências.

4.4.2 Rota B: modelo paramétrico de tempo de falha acelerado (AFT)

- a) Considere distribuições compatíveis com a disciplina, como Weibull, exponencial, log-normal ou log-logística, e justifique as candidatas avaliadas.
- b) Compare os ajustes por critérios de informação, inspeção gráfica e diagnóstico de resíduos; a menor AIC ou BIC, isoladamente, não encerra a escolha.
- c) Apresente os coeficientes como razões de tempos, ou fatores de aceleração, com intervalos de 95% de confiança e interpretação contextual.
- d) Compare as curvas ajustadas com as estimativas não paramétricas e verifique a adequação da distribuição escolhida.
- e) Declare a parametrização usada pelo programa, pois o sinal e a forma de interpretação podem variar entre funções e distribuições.

4.4.3 Requisitos comuns às duas rotas

As covariáveis deverão ser escolhidas com justificativa substantiva e antes da interpretação dos resultados. Não faça seleção automática baseada apenas em valores de p . Informe como os dados ausentes foram tratados, verifique se o número de eventos é compatível com a complexidade do modelo, avalie a estabilidade das estimativas e apresente uma tabela final clara. Se a base não sustentar um modelo multivariável, demonstre objetivamente a limitação e consulte o professor sobre a estratégia adequada.

4.5 Análise crítica e reprodutibilidade

Discuta qualidade do seguimento, viés de seleção, erros de classificação, confundimento, dados ausentes, precisão, possibilidade de generalização e limites causais. Quando uma decisão de tratamento dos dados puder alterar as conclusões, realize ao menos uma análise de sensibilidade simples ou explique por que ela não é viável.

O código deverá ser comentado e executável do início ao fim, sem caminhos absolutos e sem etapas manuais não documentadas. Fixe uma semente em qualquer procedimento aleatório, identifique os pacotes utilizados e confira se números, tabelas e gráficos do relatório podem ser reproduzidos pelo código entregue.

5 Estrutura do relatório

O relatório deverá ter entre 6 e 10 páginas, sem contar capa, referências e apêndices, e conter:

1. capa e identificação do estudante;
2. resumo com objetivo, métodos, resultado principal e conclusão;
3. introdução e pergunta de pesquisa;
4. material e métodos, incluindo coorte, variáveis, tempo, evento, censura, métodos não paramétricos e rota de modelagem escolhida;
5. resultados, na mesma ordem dos métodos e sem repetir desnecessariamente em texto todos os valores de tabelas;
6. discussão das evidências, limitações e implicações;
7. conclusão diretamente vinculada à pergunta de pesquisa;
8. referências e, se necessário, apêndices.

Tabelas e figuras deverão ser numeradas, citadas no texto, legíveis e acompanhadas de título, unidades, legendas e tamanho amostral pertinente. Evite capturas de tela de saídas do R.

6 Produtos e seminário

Deverão ser entregues:

1. relatório técnico em PDF;
2. código-fonte em `.R`, `.Rmd` ou `.qmd`;
3. arquivo breve de instruções, quando necessário, para reproduzir a análise.

Os nomes dos arquivos deverão começar pelo número de matrícula. Não entregue cópias desnecessárias das bases originais. O prazo, o local de envio e a ordem das apresentações serão informados no Google Classroom.

O seminário terá duração máxima de 15 minutos, seguida de arguição. Cada estudante deverá apresentar seu próprio trabalho, demonstrar domínio das decisões tomadas e interpretar os resultados no contexto da pesquisa. Os slides deverão priorizar a pergunta, a construção da coorte, os resultados principais, a adequação do modelo, as limitações e a conclusão.

Plágio, fabricação de resultados ou omissão deliberada de problemas relevantes da base invalidam a parte correspondente da avaliação. O uso de ferramentas de inteligência artificial é permitido, deverá ser declarado e não substitui a responsabilidade do estudante pelo código, pelas decisões e pelas interpretações.

Uma análise estatística responsável começa por verificar se os dados permitem responder à pergunta proposta.